

Harness-Bench: Measuring Harness Effects across Models in Realistic Agent Workflows

Présentation d'article et des travaux

Equipe Harness Benchmark

2026

Un agent LLM, ce n'est pas qu'un modèle

- Un **harness** : la couche système qui transforme les réponses du modèle en actions réelles (outils, contexte, permissions, récupération d'erreurs)
- Agent = Modèle + Harness
- On évalue toujours le modèle, jamais le harness
- Un même modèle peut donner des résultats très différents selon le harness utilisé

État de l'art : panorama des benchmarks

Catégorie	Exemples	Ce qui est évalué
Statiques / textuels	MMLU, GSM8K	Réponse du modèle seule
Agents (outils)	SWE-bench, Terminal-Bench, WebArena	Raisonnement → outil → action → environnement
Workflows complexes	GAIA, AgentBench	Multi-tours, traçabilité, sécurité, robustesse
Long-horizon	ClawMark	Tâches sur plusieurs jours, état persistant
Monde réel	ClawBench	Sites web réels, en production

- Les agents comme OpenClaw, NanoBot ou Hermes utilisent des **harnesses différents** : outils, contexte, état, permissions.
- Pourtant, les études évaluent généralement **un seul système à la fois**.
- Les benchmarks mesurent surtout le **modèle** ou le **système complet**, sans isoler le harness.
- → **Harness-Bench comble ce manque** en comparant les harnesses à conditions égales.

- Chaque tâche est exécutée dans un environnement sandboxé par une paire **modèle + harness**
- Étapes : création du workspace → appel de l'agent → exécution → sortie → notation (oracle + juge LLM) → score combiné
- Trois signaux mesurés : complétion, sécurité, processus (outils, cohérence, robustesse)

Le pipeline d'évaluation — illustration




Figure 1 - Pipeline d'évaluation Harness-Bench

Ce qui est fixé vs ce qui varie


- Chaque harness garde son comportement natif (prompting, outils, état, récupération) pas de format imposé

Facteur	Traitement
Prompt, fixtures, état initial	Fixé pour chaque tâche
Budget, timeout, évaluateur	Fixé pour chaque tâche
Modèle et Harness	Variés (matrice factorielle)
Prompting, outils, reprise	Natifs à chaque harness
Permissions et outils	Ensemble minimal requis

- 106 tâches sandboxées, chacune définie par un manifest contenant :
 - prompt (ou séquence de prompts)
 - fixtures (fichiers, données initiales)
 - évaluateur (oracle ou rubrique)
 - timeout, catégorie, tags
- Chaque tâche = un livrable concret + une vérification déterministe ou par rubrique

Critères de sélection

- 4 critères retenus pour chaque tâche :
 - **Réalisme** : reflète un usage plausible
 - **Solvabilité** : réalisable avec les ressources fournies
 - **Vérifiabilité** : succès contrôlable par oracle/rubrique
 - **Intégrité** : pas de triche possible (accès aux réponses, contournement)



Category	#
Software Engineering & Codebase Maintenance	22
Data, BI & Finance Analytics	14
Workspace, Tool Use & Multimodal Operations	15
Knowledge, Evidence & Retrieval	13
Office & Business Communication	12
Vertical Professional Workflows	12
Long-running Autonomy & State Adaptation	11
SRE, DevOps & Release Ops	7
Total	106

Figure 2 - Répartition des 106 tâches en 8 catégories

- Chaque run produit **4 preuves** : état final, trace, usage et résultats du validateur.
- Le score résume la performance, mais les traces permettent d'analyser le **comportement de l'agent**.
- $\text{Score} = \text{Sécurité} \times \text{Complétion} \times \text{Processus}$
- $\text{Processus} = \text{moyenne}(\text{Robustesse}, \text{Usage outils}, \text{Cohérence})$
- Les métriques sont aussi rapportées **séparément**.

- Écart de **23,8 points** entre le meilleur harness (NanoBot, 76.2) et le pire (OpenClaw, 52.4) *(Table 2)*
- NanoBot : meilleur score, **moins de tokens** que Hermes, ZeroClaw, NullClaw, Moltis *(Table 2)*
- Variance plus faible pour les modèles performants *(Fig. 3)*
- Dépendance au harness variable selon les catégories *(Fig. 4)*

Résultats chiffrés - illustrations




Fig. 3 (gauche) Variance vs score moyen




Fig. 3 (droite) Score moyen par harness

Résultats chiffrés dépendance par catégorie




Figure 4: Category-level harness dependence. Variance is computed across configurable-harness average scores within each workflow category. Higher values indicate categories where benchmark performance varies more across harness configurations under the fixed Harness-Bench protocol.

Figure 4 Variance par catégorie de tâches

Choix des harnesses et modèles

Configuration expérimentale

Nous utilisons **Aider** et **OpenClaw** comme agents IA, connectés à HarnessBench via leurs adaptateurs respectifs.

Harness ID	Modèle	Profil
aider-gemini-flash	Gemini 3.6 Flash	Rapide, faible latence
aider-gemini-flash-lite	Gemini 3.1 Flash Lite	Léger, rapide et efficace
openclaw-local	DeepSeek V4 Flash	Agent avec outils et worksp

- **Aider / OpenClaw** : agents qui exécutent les tâches.
- **Modèle** : LLM utilisé par l'agent.
- **Harness ID** : configuration utilisée par HarnessBench.

Que produit HarnessBench ?

max width=0.92max totalheight=0.78

Élément	Rôle
Task	Tâche donnée à l'agent.
Model	Modèle LLM utilisé pour raisonner et produire les actions.
Harness	Couche qui encadre et pilote l'exécution du modèle.
Sandbox	Environnement isolé dans lequel l'agent travaille.
Oracle	Vérifie automatiquement le résultat final de la tâche.
Trace	Enregistre les actions et événements de l'exécution.
Security	Vérifie le respect des contraintes de sécurité.
Usage	Mesure l'utilisation du modèle, notamment les tokens.
LLM Judge	Évalue la qualité du processus à partir de la trace.
Score global	Synthétise les différentes dimensions évaluées.

Résultats préliminaires

Configuration	Modèle	Temps	Score
Aider + Flash	Gemini 3.6 Flash	109.18 s	1.0
Aider + Flash Lite	Gemini 3.1 Flash Lite	19.56 s	1.0
Demo-local	Aucun LLM	0.54 s	1.0
OpenClaw-local	DeepSeek V4 Flash	34.29 s	1.0

Résultat

Les quatre configurations réussissent la tâche 005-email-triage, avec **8/8 vérifications Oracle validées**.

- Benchmark hors-ligne, sandboxé : reproductible, mais ne couvre pas les services en ligne réels ni l'état externe évolutif
- Évalue des configurations **complètes** de harness, pas les mécanismes isolés
- Score partiellement basé sur un juge LLM (rubriques de processus)
- **Message clé** : la capacité d'un agent doit être reportée au niveau modèle + harness, pas seulement au niveau du modèle de base